

Data Mining

Descoberta de conhecimento em dados, KDD, pré-processamento e mineração

Prof. Me. Otávio Parraga

Bacharelado em Ciência de Dados e Inteligência Artificial

MALTA
Machine Learning Theory
and Applications Lab



Quem sou eu



Prof. Me. Otávio Parraga



MALTA

Machine Learning Theory
and Applications Lab

FORMAÇÃO

Mestre em Ciência da Computação · Bacharel em Sistemas de Informação


ATUAÇÃO & PESQUISA

Aprendizado de máquina · Processamento de Linguagem Natural · Redes Neurais

LABORATÓRIO

MALTA Lab, Machine Learning Theory and Applications, Escola Politécnica da PUCRS.

Atuação



O panorama da disciplina

DIA 1 · 6H Fundamentos, dados e preparação

- 01** O que é Data Mining
- 02** Dados e Estatística Descritiva
- 03** Armazenamento
- 04** Pré-processamento
- 05** Amostragem e Geração

DIA 2 · 4H Mineração: modelos e avaliação

- 01** Conceitos de Machine Learning
- 02** Aprendizado supervisionado
- 03** Avaliação de modelos
- 04** Aprendizado não-supervisionado
- 05** Aprendizado Profundo

A trilha de hoje

01 O que é Data Mining

Definições · onde se insere · KDD, CRISP-DM e SEMMA · o fluxo de um projeto

02 Dados e Estatística Descritiva

Tipos de dados · tendência central e dispersão · visualização · associação

03 Armazenamento de Dados

SQL · NoSQL · data warehouses e data lakes · formatos (CSV, JSON, Parquet)

04 Pré-processamento de Dados

Limpeza (ausentes, duplicados, outliers) · transformações · feature engineering

05 Amostragem e Geração de Dados

População × amostra · desbalanceamento · SMOTE e dados sintéticos

O que é Data Mining

Definições, onde a área se insere, os processos que a organizam (KDD, CRISP-DM, SEMMA) e o fluxo de trabalho.

01

Por que precisamos de Data Mining?

1 · A PERGUNTA

- Quais produtos vão vender mais no próximo **inverno**?
- Quais clientes estão prestes a **abandonar**?
- Onde estão os **defeitos** na linha de produção?

BUSCAMOS
OS DADOS



2 · A REALIDADE: UMA BASE GIGANTE E SUJA

Ana	38°C	?	R\$ 1.000	SP
ana	38 C	sim	NULL	SP
Bruno	—	não	1500	rj
Bruno	36°C	não	1500	RJ
Carla	41°C	sim	abc	MG

milhões de linhas

valores ausentes

duplicatas

formatos misturados

O que é Data Mining

A IDEIA CENTRAL

Mineração de dados une **estatística**, **aprendizado de máquina** e **banco de dados** para extrair informação útil de grandes bases.

EXEMPLOS DE USO


- **Previsão de demanda:** quanto vender no próximo inverno
- **Detecção de fraude:** transações fora do padrão
- **Segmentação de clientes:** agrupar perfis de compra
- **Recomendação:** "quem comprou X também levou Y"
- **Manutenção preditiva:** prever falhas por sensores (IoT)

ONDE SE ENCAIXA Data mining é o **passo central** de um processo maior de descoberta de conhecimento, o **KDD**.

Onde o Data Mining se insere


TRÊS FUNDAMENTOS

- **Estatística:** inferência, distribuições, incerteza
- **Aprendizado de Máquina :** algoritmos que aprendem padrões
- **Bancos de Dados:** armazenar e consultar grandes volumes



KDD: Knowledge Discovery in Databases

O processo completo de transformar **dados brutos em conhecimento**. O data mining é o seu passo central, mas a maior parte do esforço está na **preparação**.



Processo iterativo: a qualquer momento pode-se voltar a etapas anteriores conforme o que se aprende.

Fayyad, Piatetsky-Shapiro & Smyth (1996), AI Magazine

Os processos de Data Mining

Três formalizações clássicas. Nomes e números mudam, a **espinha dorsal** é a mesma.

KDD

Acadêmico · Fayyad et al., 1996

- 1 · Seleção
- 2 · Pré-processamento
- 3 · Transformação
- 4 · **Data Mining**
- 5 · Interpretação / Avaliação

CRISP-DM

Padrão de mercado · cíclico

- 1 · Entendimento do Negócio
- 2 · Entendimento dos Dados
- 3 · Preparação dos Dados
- 4 · **Modelagem**
- 5 · Avaliação · 6 · Implantação


SEMMA

SAS Institute · fase analítica

- Sample:** amostrar
- Explore:** explorar
- Modify:** transformar
- Model:** modelar
- Assess:** avaliar

MESMA ESPINHA DORSAL Entender › preparar › modelar › avaliar, e iterar. O processo é sempre cíclico, não linear.

CRISP-DM: Cross-Industry Standard for Data Mining



O fluxo de um projeto de Ciência de Dados








Figure 2-2. The data science process

Fonte: Schutt, R.; O'Neil, C., Doing Data Science, O'Reilly, 2013

Muitos fluxogramas, as mesmas etapas



Data Mining como uma função



Etapas comuns a todo fluxo

1 Entendimento do Negócio e dos Dados

2 Coleta de Dados

3 Pré-processamento

4 Análise de Dados

5 Modelagem

6 Avaliação

7 Implantação

Entendimento e Coleta de Dados

Tudo começa entendendo o **negócio e os dados** . A coleta, então, lida com fontes muito diversas:

- Diferentes **fontes**
- Diferentes **formatos**
- Diferentes **acessos**
- Diferentes **preocupações**



Pré-processamento de Dados


Manipular os dados para facilitar o trabalho:

- **Limpeza**
- **Transformações**
- **Correções**

É, em geral, a etapa **mais onerosa** de todo o projeto.



Garbage in, garbage out



Na ciência de dados, a **qualidade dos dados** pesa mais que a complexidade do modelo, por isso o pré-processamento é a etapa mais decisiva.

Análise de Dados

- **Estatística descritiva**

Média, moda, mediana, desvio padrão...

- **Visualização de dados**


Como extrair informações úteis?



Modelagem

Transforma os dados em **produto**:

- Automatização de tarefas
- Predição de eventos e tendências
- Extração de insights
- **Machine Learning**: matemática aplicada



Avaliação e Implantação

Avaliação

- Meu modelo está bom ou não?
- Comparar modelos e garantir comportamentos
- A avaliação depende da tarefa realizada

Implantação

- Entrada em produção do projeto
- Efetiva o apoio à tomada de decisão
- Plano de entrega: monitoramento, sustentação e documentação

Dados e Estatística Descritiva

O que são dados, como se organizam e os tipos; as medidas que resumem, descrevem e relacionam atributos.

02

O que são dados?

Dados são **registros brutos** de fatos, observações ou medições, ainda *sem* contexto ou interpretação.

- São a **matéria-prima** de todo o processo
- Isolados, dizem pouco, ganham valor com **contexto**
- Podem ser números, texto, imagens, sinais...

37,8

um número sozinho é só um dado

37,8 °C de febre já é informação

A pirâmide do conhecimento (DIKW)



Dados	registros brutos, <i>o quê</i>
Informação	dado com contexto, <i>quem, quando, onde</i>
Conhecimento	padrões e relações, <i>como</i>
Sabedoria	decisão aplicada, <i>por quê e o que fazer</i>

Estruturados × não-estruturados

Estruturados

São dados com um formato bem definido.

Um ótimo exemplo são tabelas, todas as linhas possuem as mesmas colunas!

Não-estruturados

Sem formato definido, e a **maioria** dos dados disponíveis:

Imagens

Textos

Áudios

Vídeos

Conjunto de dados (dataset)

$$X \in \mathcal{R}^{N \times m}$$

Linhas N

- Instâncias *instances*
- Objetos *objects*
- Exemplos *examples*
- Tuplas *tuples*
- Amostras *samples*
- Casos *cases*
- Registros *records*
- Vetores de características *feature vectors*

Colunas m

- Atributos *attributes*
- Características *features*
- Campos *fields*
- Variáveis *variables*
- Dimensões *dimensions*

M ATRIBUTOS →

N INSTÂNCIAS ↑

	$\mathbf{x}_1$	$\mathbf{x}_2$	...	$\mathbf{x}_m$
$\mathbf{X}^{(1)}$	$\mathbf{x}_1^{(1)}$	$\mathbf{x}_2^{(1)}$	...	$\mathbf{x}_m^{(1)}$
$\mathbf{X}^{(2)}$	$\mathbf{x}_1^{(2)}$	$\mathbf{x}_2^{(2)}$	...	$\mathbf{x}_m^{(2)}$
	$\vdots$	$\vdots$	$\ddots$	$\vdots$
$\mathbf{X}^{(N)}$	$\mathbf{x}_1^{(N)}$	$\mathbf{x}_2^{(N)}$	...	$\mathbf{x}_m^{(N)}$

$x_j^{(i)}$ = valor do atributo j na instância i

Dados estruturados (geralmente) vivem em uma matriz

linhas → instâncias · registros · amostras · exemplos · objetos

colunas → atributos · variáveis · features · campos · dimensões

Produto	Preço (R\$)	Categoria	Estoque
Faca 3"	29,90	Cutelaria	1240
Panela 20cm	159,00	Cozinha	530
Tesoura	39,90	Cutelaria	870
Alicate	54,00	Ferramentas	410
Pá de jardim	42,50	Jardinagem	295

NÃO CABEM NA MATRIZ



Imagem



Texto



Áudio

Precisam ser **convertidos** (vetorizados) antes de entrar em um modelo, e nessa conversão alguma informação se perde.

Dados textuais

A modalidade mais **abundante**: linguagem humana. O computador não lê palavras, primeiro é preciso transformá-las em números.

EXEMPLO · DE TEXTO CRU A DADO

“A panela é **ótima**, mas o cabo **esquentou** demais.”



TOKENS

panela é ótima mas cabo esquentou demais

CONTAGEM

{ ótima: 1, cabo: 1, esquentou: 1, ... }

SENTIMENTO

+ elogio: produto - queixa: cabo

ONDE APARECE

- **Avaliações** de produtos no e-commerce
- E-mails e **tickets de suporte**
- Contratos e documentos
- Posts e menções em redes sociais


TAREFAS TÍPICAS

- **Análise de sentimento** e classificação de tópicos
- Extração de entidades (produto, defeito)
- **Busca semântica** e recomendação

Dados de imagem

Toda imagem é uma **grade de pixels**; cada pixel, um conjunto de números. Em cor, são **3 valores (R, G, B)** de 0 a 255.

EXEMPLO · A FOTO É UMA MATRIZ DE NÚMEROS



ONDE APARECE

- **Fotos de produtos** no catálogo e e-commerce
- Imagens de **inspeção de defeitos** na fábrica
- Exames médicos (raio-X, ressonância)
- Imagens de satélite e mapas

TAREFAS TÍPICAS

- **Classificação**: é um defeito? que produto é?
- **Detecção** e segmentação de objetos
- **OCR**: ler texto dentro da imagem

O tipo de dado define as ferramentas

Em cada etapa do processo, o tipo de dado muda as perguntas certas a fazer:

① Como analisar e visualizar os dados?

② Quais os processamentos necessários?

③ Quais modelos podem ser aplicados?

④ Como avaliar corretamente o que foi feito?

Exemplo: diagnóstico de uma doença

Paciente	Temperatura	Dor	Pressão	Diagnóstico
paciente 1	38 °C	sim	12.7	doente
paciente 2	36 °C	não	12.1	saudável
paciente N	40 °C	não	14.0	doente

■ Numérico (quantitativo) ■ Categórico (qualitativo) ■ Atributo-meta (classe / rótulo)

Quatro tipos de atributos

O tipo define a visualização, a análise, o processamento, o modelo e a avaliação.

Nominal · qualitativo

cor, profissão, tipo sanguíneo

Ordinal · qualitativo

qualidade (ruim, médio, bom), dias da semana

Intervalar · quantitativo

data, temperatura em Celsius

Racional · quantitativo

peso, idade, temperatura em Kelvin

Cada coluna tem um tipo

Nome	Temp	Enjôo	Mancha	Dor	Salário	Diagnóstico
João	37.7	sim	pequena	sim	1000	doente
Pedro	37.0	não	pequena	não	1100	saudável
Maria	38.2	sim	grande	não	600	saudável
José	39.0	não	pequena	sim	2000	doente
Ana	37.3	não	grande	sim	1800	saudável
–	Intervalar	Nominal	Ordinal	Nominal	Racional	Classe

Por número de valores

Contínuos

Quantidade incontável de valores, números reais: temperatura, peso, distância.

Discretos

Número contável (finito ou infinito): estações do ano, nº de filhos, código postal.

Caso especial, Binários: 0/1, V/F, S/N

Atributos binários assimétricos

- Assume dois valores, mas **só um é relevante** (indica que a instância tem a característica).
- Ex.: a presença de cada palavra em um e-mail, só importa quando a palavra aparece (1); a ausência (0) é o caso comum.
- Identificá-lo é importante no projeto de sistemas de AM. Cenário clássico: **text mining**.

E-mail	grátis	oferta	clique	reunião	fatura
E-mail 1	1	1	1	0	0
E-mail 2	0	0	0	1	1
E-mail 3	1	0	1	0	0
E-mail 4	0	0	0	0	0

Por que explorar antes de modelar

- Facilita o entendimento das características dos dados
- Ajuda a escolher a melhor técnica de pré-processamento ou aprendizado
- Apoia-se em **estatística descritiva** e **visualização**

A ESTATÍSTICA DESCRITIVA CAPTURA

Frequência

Localização (tendência central)

Dispersão (espalhamento)



Distribuição (formato)

Frequência

RELEMBRANDO OS DADOS

Paciente	Temp	Mancha	Dor	Diagnóstico
João	37.7	pequena	sim	doente
Pedro	37.0	pequena	não	saudável
Maria	38.2	grande	não	saudável
José	39.0	pequena	sim	doente
Ana	37.3	grande	sim	saudável

Proporção de vezes que um atributo assume um dado valor, usada sobretudo para atributos **categóricos** . Basta **contar** na tabela.



Medidas de localidade

DADOS CATEGÓRICOS

Moda

O valor mais frequente. Ex: a moda do atributo "mancha" é **grande**.

DADOS NUMÉRICOS

Média · Mediana · Percentil

Diferentes formas de descrever o "centro" de um conjunto de valores.

Média

$$\bar{x}_j = \frac{1}{N} \sum_{i=1}^N x_j^{(i)}$$

Soma dos valores dividida pela quantidade de observações.

ATENÇÃO

É sensível a **outliers**, poucos valores extremos distorcem o resultado.

Como ler um somatório (Σ)

O símbolo grego **sigma** quer dizer apenas uma coisa: **some tudo**. Os rótulos dizem de onde até onde.

$$\sum_{i=1}^n x_i$$

- **i = 1** (embaixo): por onde a soma **começa**
- **n** (em cima): onde a soma **termina**
- **x_i** (à direita): o **termo** somado a cada passo

Lê-se: $x_1 + x_2 + \dots + x_n$ Ex.: $x = [4, 8, 6] \rightarrow \Sigma = 4 + 8 + 6 = \mathbf{18}$

A **média** é só um somatório dividido por n: $\bar{x} = (1/n) \Sigma x_i$

Mediana, e quando preferir cada uma

- Menos sensível a outliers que a média
- Exige **ordenar** os valores, maior complexidade

Com os valores ordenados $x_{(1)} \leq \dots \leq x_{(n)}$:

n ímpar: mediana = $x_{((n+1)/2)}$

n par: mediana = $\frac{1}{2} \cdot (x_{(n/2)} + x_{(n/2+1)})$

Use a média



quando os valores são distribuídos de forma simétrica

Use a mediana

se a distribuição é assimétrica (skewed) ou há outliers


O que é uma distribuição

A **distribuição** de um atributo descreve *quais valores ele assume e com que frequência*, a forma do espalhamento dos dados.



Normal (simétrica)

média $\approx$ mediana $\approx$ moda



Assimétrica (enviesada)

cauda longa puxa a média



Uniforme


todos os valores igualmente prováveis

POR QUE É RELEVANTE

- Define qual **medida resumo** usar (média $\times$ mediana)
- Sinaliza **outliers** e a necessidade de transformação (ex.: log)
- É premissa de muitos modelos e da **padronização (z-score)**
- Orienta a **amostragem** e a geração de dados sintéticos

Exemplo: renda × altura


Renda mensal, assimétrica à direita



■ Mediana R\$ 2.800 ■ Média R\$ 4.100

Use a **mediana**, a cauda de altos salários infla a média.

Altura adulta, aproximadamente normal



■ Média ≈ Mediana = 1,70 m

Aqui a **média** resume bem, distribuição simétrica.

Medidas de espalhamento

Indicam se um atributo está amplamente espalhado ou concentrado em torno de um ponto (ex.: a média).

Intervalo

Espalhamento máximo (máx – mín)

Variância

Dispersão em torno da média

Desvio padrão

Raiz quadrada da variância

Cuidado com o intervalo: valores concentrados, mas com poucos extremos, podem enganar.

Variância e desvio padrão

Variância

$$\sigma^2 = \frac{1}{n - 1} \sum (x_i - \bar{x})^2$$

Denominador (n – 1): correção de Bessel, melhor estimativa da variância real

Desvio padrão

$$\sigma = \sqrt{(\sigma^2)}$$

Raiz quadrada da variância, na mesma unidade dos dados

Média e desvio padrão na prática

Tempo de entrega de 5 pedidos (em dias). Quão centrados e quão espalhados eles estão?


3 5 4 6 7 dias

MÉDIA

$$\bar{x} = (3+5+4+6+7) / 5 = 25 / 5 = \mathbf{5 \text{ dias}}$$

DESVIO PADRÃO


$$\Sigma(x_i - \bar{x})^2 = (-2)^2 + 0^2 + (-1)^2 + 1^2 + 2^2 = \mathbf{10} \quad \sigma^2 = 10 / (5-1) = 2,5 \rightarrow \sigma = \sqrt{2,5} \approx \mathbf{1,58 \text{ dia}}$$



A faixa $\bar{x} \pm 1\sigma = [3,4 ; 6,6]$ dias concentra a maioria dos pedidos. Quanto menor o σ , mais previsível é a entrega.

Visualização de dados

A forma mais rápida de enxergar a forma dos dados. Cada gráfico responde a uma pergunta diferente.




Histograma

distribuição de uma variável



Boxplot

mediana, quartis e outliers



Dispersão

relação entre duas variáveis



Barras

comparar categorias

Covariância

$$\text{cov}(\mathbf{x}, \mathbf{y}) = \sum (\mathbf{x}_i - \bar{\mathbf{x}})(\mathbf{y}_i - \bar{\mathbf{y}})$$

Na análise sobre vários atributos, a **covariância** mede o grau com que dois atributos variam juntos.

$$\text{cov}(\mathbf{x}_j, \mathbf{x}_k) = \frac{1}{(N - 1)} \sum_{i=1}^N (x_j^{(i)} - \bar{x}_j)(x_k^{(i)} - \bar{x}_k)$$

O espalhamento de um dataset multivariado pode ser capturado por uma **matriz de covariância**, em que cada elemento é a covariância de um par de atributos.

Problema: covariância varia entre $-\infty$ e $+\infty$.

Correlação de Pearson

A covariância não deixa claro o relacionamento; a **correlação** indica a relação linear entre duas variáveis e é preferível para explorar dados.

- Despreza média e variabilidade (normaliza pelos desvios)

$$\text{corr}(\mathbf{x}_j, \mathbf{x}_k) = \frac{\text{cov}(\mathbf{x}_j, \mathbf{x}_k)}{\sigma_{\mathbf{x}_j} \sigma_{\mathbf{x}_k}}$$


+1 / -1

relação linear positiva / negativa perfeita

0


sem relação **linear**, mas pode haver relação não-linear!

Análise visual da correlação




Dispersão de um par de atributos para correlações de $-1,0$ a $+1,0$


Correlação não indica causalidade




Correlação não indica causalidade



Correlação não indica causalidade




Correlação não indica causalidade



Correlação aplicada: preço × volume de vendas

Dispersão: preço (R\$) × vendas/mês



CORRELAÇÃO DE PEARSON

$$r = -0,83$$

negativa e **forte** (próxima de -1)

Leitura

Quanto **maior o preço**, menos unidades por mês: produtos **premium giram menos** em volume. Útil para pensar o trade-off margem × giro.

Cuidado


Correlação **orienta a exploração, não prova causa** : o preço é só um fator, categoria, canal e sazonalidade também pesam.

Armazenamento de Dados

Onde os dados vivem: bancos relacionais e NoSQL, e os formatos mais comuns.


03

Onde armazenar os dados




Relacional

Tabelas que se relacionam. SQL é o padrão. Exige modelo de dados prévio.



Não-relacional

Para aplicações massivamente paralelas e distribuídas. Sem modelo prévio.



Vetorial

Para demandas de aprendizado profundo. Busca por similaridade entre vetores.

Banco de dados relacional

Modelo proposto por **Edgar F. Codd (1970)**. Os dados vivem em **tabelas** (relações) de linhas e colunas, e as tabelas se conectam por **chaves**. A linguagem padrão para criá-las e consultá-las é o **SQL**.

Esquema fixo

A estrutura (colunas e tipos) é definida **antes** de inserir os dados.

Garantias ACID

Transações confiáveis: atomicidade, consistência, isolamento e durabilidade.

Chaves

PK identifica cada linha; **FK** liga uma tabela a outra.

SGBDs

PostgreSQL, MySQL, Oracle, SQL Server.

Como se organiza: tabelas ligadas por chaves

tabela clientes

id PK	nome	cidade
1	Cozinha Sul	Porto Alegre
2	Lar & Mesa	Curitiba
3	Bazar Pampa	Recife

CHAVE
ESTRANGEIRA



cliente_id
aponta para
clientes.id

tabela pedidos

id PK	cliente_id FK	produto	valor
10	1	Jogo de facas	R\$ 220
11	3	Jogo de panelas	R\$ 980
12	1	Frigideira	R\$ 90

Cada pedido da Tramontina guarda apenas o **id** da loja, não seus dados repetidos. A ligação por chaves evita redundância, é o coração do modelo relacional.

As tabelas da Tramontina

Guarde estas duas tabelas da Tramontina — **clientes** (as lojas que revendem) e seus **pedidos**: a consulta a seguir vai **cruzá-las** pela chave **cliente_id**.

tabela clientes

id PK	nome	cidade
1	Cozinha Sul	Porto Alegre
2	Lar & Mesa	Curitiba
3	Bazar Pampa	Recife

LIGADAS POR
CHAVE



cliente_id
aponta para
clientes.id

tabela pedidos

id PK	cliente_id FK	produto	valor
10	1	Jogo de facas	R\$ 220
11	3	Jogo de panelas	R\$ 980
12	1	Frigideira	R\$ 90

SQL na prática: uma consulta

```
SELECT c.nome, p.produto, p.valor
FROM clientes AS c
JOIN pedidos AS p ON p.cliente_id = c.id
WHERE p.valor > 100
ORDER BY p.valor DESC;
```

RESULTADO

nome	produto	valor
Bazar Pampa	Jogo de panelas	R\$ 980
Cozinha Sul	Jogo de facas	R\$ 220

O pedido de R\$ 90 (Frigideira) ficou de fora pelo **WHERE**; o **JOIN** trouxe o nome do cliente que estava na outra tabela.

"Liste o nome do cliente, o produto e o valor de todos os pedidos acima de R\$ 100, do mais caro ao mais barato."

Palavras-chave do SQL

SELECT

Escolhe **quais colunas** aparecem no resultado (use * para todas).

FROM

Indica **de qual tabela** os dados vêm.

WHERE

Filtra as linhas por uma condição (ex.: valor > 100).

JOIN

Combina tabelas ligando-as por uma chave (ON).

GROUP BY

Agrupa linhas para agregar (SUM, COUNT, AVG por grupo).

ORDER BY

Ordena o resultado, ASC (crescente) ou DESC (decrescente).


Bancos NoSQL

"Not only SQL". Família de bancos de **esquema flexível**, criados para **volume, variedade e velocidade** e que escalam **horizontalmente** (distribuídos em vários servidores). Reúne quatro modelos principais:




Documento

Registros em JSON. **MongoDB**



Chave-valor

Dicionário gigante. **Redis**



Coluna larga

Escala massiva. **Cassandra**



Grafo

Nós e relações. **Neo4j**

Como se organiza: documentos

```
{ "_id": "u-1024", "nome": "Ana Lima", "cidade": "Porto Alegre", "tags": ["premium", "newsletter"], "endereco": { "rua": "Av. Ipiranga", "num": 6681 } }
```

- Cada registro é um **documento autossuficiente**, sem precisar de outras tabelas.
- Aceita campos **aninhados** (endereço) e **listas** (tags).
- Outro usuário pode ter campos **diferentes**, o esquema não é fixo.

Em vez de espalhar os dados por várias tabelas, tudo o que descreve um usuário fica junto, em um só documento.

Na prática: catálogo de e-commerce

CONSULTA (MONGODB)

```
db.produtos.find ( { categoria: "tênis", preco: { $lt: 300 } } ).sort({ avaliacao: -1 })
```

"Tênis abaixo de R\$ 300, do mais bem avaliado para o menos."

POR QUE NOSQL AQUI

Atributos variam por produto

Tênis tem **numeração**, livro tem **autor** e **ISBN** . Cada documento guarda só os campos que fazem sentido.

Escala e velocidade

Milhões de itens e picos de acesso distribuídos por vários servidores, sem reescrever o esquema.

Banco de dados vetorial

Armazena **embeddings**: vetores numéricos de alta dimensão que capturam o **significado** de textos, imagens ou áudios. Em vez de buscar valores exatos, busca por **similaridade**, os vizinhos mais próximos no espaço.

Embedding Conteúdo virado vetor por um modelo.	Similaridade Distância de cosseno entre vetores.	Busca ANN Vizinhos próximos de forma aproximada e rápida.	SGBDs Pinecone, Milvus, Weaviate, pgvector.
--	--	---	---


Como se organiza: pontos no espaço

```
"gato preto dorme"  
// modelo de embedding →  
[ 0.82, -0.13, 0.44, 0.07, ... 768 dims ]
```

Um modelo transforma cada conteúdo em um vetor de centenas de dimensões. Significados parecidos caem **perto**; significados distantes ficam **longe**.



Na prática: busca semântica e RAG



A busca acha o trecho certo **mesmo sem repetir as palavras** da pergunta: "cancelar" encontra "encerrar plano" porque os vetores estão próximos em **significado**.

Quando usar cada banco de dados

Relacional · SQL

USE QUANDO...

- Dados **estruturados** e esquema estável
- Precisa de **transações confiáveis** (ACID)
- **Relações** claras entre entidades (JOINS)
- Relatórios e **BI** consistentes

NoSQL

USE QUANDO...

- **Esquema flexível** ou atributos variáveis
- Altíssimo **volume e velocidade** (escala horizontal)
- Documentos, cache, séries temporais, grafos
- Prototipagem **sem modelo prévio**

Vetorial

USE QUANDO...

- Busca por **similaridade** (significado, não palavra exata)
- **Embeddings** de texto, imagem, áudio
- **RAG** e recomendação semântica

SQL — QUANDO SIM

Dados tabulares com relações, transações que não podem falhar, e consultas ad-hoc com a linguagem mais difundida do mercado.

SQL — QUANDO EVITAR

Esquema que muda toda hora, escala web massiva e distribuída, ou dados não-estruturados como imagens e embeddings.

Formatos de dados

CSV texto · tabular

```
id,nome,idade 1,Ana,29 2,Bruno,34
```

- Universal e legível
- Sem tipos; pesado em volume

JSON texto · aninhado

```
{ "nome": "Ana", "tags": ["pro","sp"] }
```

- Estruturas aninhadas; padrão em APIs
- Verboso em massa

Parquet binário · colunar

col A	col B	col C
-------	-------	-------

- Comprime muito; lê só as colunas usadas
- Padrão em **big data** e analytics

Ou simplesmente armazenar os dados


Dependendo do tipo de dado e da tarefa, um armazenamento é preferível ao outro, ou basta guardar sem organização específica:

HD

Memória barata, porém mais lenta

SSD

Memória cara, porém muito mais rápida



Pré-processamento de Dados

Limpar e transformar os dados, a etapa mais trabalhosa e a que mais define a qualidade do resultado.

04

Limpar e transformar

Duas grandes famílias de operações, e a etapa que mais consome tempo no projeto.

1 · Limpeza

Corrigir problemas de **qualidade** dos dados.

- Valores **ausentes**
- Valores **duplicados**
- **Outliers** e inconsistências
- **Anonimização** de dados pessoais **LGPD**

2 · Transformação

Adaptar os dados aos **algoritmos**.

- **Normalização** e padronização
- **Codificação** de variáveis categóricas
- **Feature engineering**

LEMBRE-SE *Garbage in, garbage out*, nenhum modelo compensa dados mal preparados.

Valores Ausentes: descartar o que falta

A opção mais simples, excluir **linhas** (listwise) ou **colunas** com ausência massiva.

Antes (5 clientes)

Cliente	Idade	Plano
Ana	29	Pro
Bruno	NaN	Free
Caio	34	Pro
Duda	NaN	Free
Edu	41	Pro

→
remove 2
linhas

Depois (só 3 clientes)

Cliente	Idade	Plano
Ana	29	Pro
Caio	34	Pro
Edu	41	Pro

Perdeu **40%** da base. Use só com poucos ausentes e falta aleatória — senão, enviesa.

Valores Ausentes: preencher os vazios

Em vez de descartar, **estima** o valor que falta, preserva o tamanho da base.

MÉTODOS COMUNS

- **Média / mediana / moda** da coluna
- Valor **constante** ou "desconhecido"
- **KNN** / regressão / interpolação (olham outras colunas)

Preserva a base, mas pode **subestimar a variância** dos dados.

MESMO VAZIO, MÉTODOS DIFERENTES

Para a idade que falta do **Bruno**, cada método dá um valor:

Média **34,7**

Mediana → próxima tela **34**

KNN → em duas telas **37,5**

○ **método muda o valor** — escolha conforme os dados.

Exemplo: imputar pela mediana

Cinco clientes, duas idades faltando. Mediana das idades observadas (29, 34, 41) = **34**.

Antes (dado bruto)

Cliente	Idade	Plano
Ana	29	Pro
Bruno	NaN	Free
Caio	34	Pro
Duda	NaN	Free
Edu	41	Pro

→
imputa
mediana

Depois (imputado)

Cliente	Idade	Plano
Ana	29	Pro
Bruno	34*	Free
Caio	34	Pro
Duda	34*	Free
Edu	41	Pro

* valor imputado, base inteira preservada (vs. perder 40% ao remover).

Imputar com KNN: olhar os vizinhos

Em vez da mediana global, o KNN estima a idade do **Bruno** pelos clientes mais parecidos nas **outras colunas**.

Clientes, comparados por renda e compras

Cliente	Renda	Compras/ano	Idade
Ana	2,8	3	29
Bruno	6,4	9	NaN
Caio	6,1	8	34
Duda	2,5	2	24
Edu	6,7	10	41

■ alvo (idade falta) ■ 2 vizinhos mais próximos

K = 2 VIZINHOS MAIS PRÓXIMOS

Por renda e compras, os mais parecidos com o Bruno são **Caio** e **Edu**.

$$\text{idade} = (34 + 41) / 2 = 37,5$$

Difere da mediana global (**34**): o KNN usa o **contexto** das outras colunas — mais poderoso, porém mais custoso.

Sinalizar: a ausência como informação

Às vezes o melhor é **registrar** que o dado faltava, a própria ausência pode carregar sinal.

Cria-se uma coluna binária **idade_ausente**

Cliente	Idade	idade_ausente
Ana	29	0
Bruno	NaN	1
Caio	34	0
Duda	NaN	1
Edu	41	0

Por que funciona

O modelo **aprende com a flag** : quem não informou a idade pode ter comportamento diferente (cadastro incompleto, plano grátis).

NA PRÁTICA

Combine: **impute o valor** e **mantenha a flag** — o modelo usa as duas informações.

Tratamento de valores duplicados

Surgem da integração de fontes, envios repetidos ou erros de coleta, e **enviesam** estatísticas e modelos.

Duplicatas em uma tabela de clientes

id	Nome	E-mail
1	Ana Souza	ana@x.com
2	Ana Souza	ana@x.com
3	Bruno Lima	bruno@x.com
4	Ana S.	ana@x.com

■ **exata** ■ parcial / fuzzy

Detectar

Por **chave** (linhas idênticas) ou por **similaridade** (fuzzy matching) quando há variações de grafia.

Tratar

Remover mantendo um **representante** . Cuidado: nem toda repetição é duplicata, pode ser evento legítimo.

Tratamento de outliers

1 · DETECTAR

- **Z-score:** valores além de $|z| > 3$
- **IQR:** fora de $[Q1 - 1,5 \cdot IQR ; Q3 + 1,5 \cdot IQR]$
- **Visual:** boxplot, histograma, dispersão
- **Modelos:** Isolation Forest, LOF, DBSCAN

2 · TRATAR

- **Remover:** quando é claramente um erro
- **Capar / winsorizar:** limitar ao percentil
- **Transformar:** log, raiz (comprime caudas)
- **Manter:** quando carrega informação real

REGRA DE OURO

Nem todo outlier é um erro.
Fraudes, falhas e descobertas *são* outliers.

Investigue a causa antes de descartar.

Exemplo: outlier num sensor

Dez leituras de temperatura (°C): 19, 20, 20, 21, 21, 21, 22, 22, 23, 92. Uma destoa.

Boxplot, o ponto fora dos limites



A "caixa" concentra 50% dos dados; o ponto vermelho está muito além do bigode superior.

REGRA DO IQR, PASSO A PASSO

$$Q1 = 20 \cdot Q3 = 22 \text{ IQR} = 22 - 20 = \mathbf{2} \text{ limite} = Q3 + 1,5 \cdot \text{IQR} = 22 + 3 = \mathbf{25}^{\circ}\text{C}$$

$92 > 25 \rightarrow$ outlier. Provável falha de sensor: **remover ou corrigir** antes de calcular a média.

LGPD

Anonimização: proteger dados pessoais

A **LGPD** (Lei 13.709/2018) obriga a tratar com cuidado todo dado que identifica uma pessoa. Antes de minerar, **removemos ou transformamos** esses identificadores — preservando o que é útil para a análise. Quatro técnicas:

Supressão

Apagar a coluna que identifica.

nome, CPF → removidos

Mascaramento · hash

Trocar por um código irreversível.

CPF → a1f9c2...

Generalização

Reduzir a precisão do valor.

idade 34 → 30–39

Agregação · ruído

Reportar só totais; perturbar valores.

média por cidade

ATENÇÃO

Pseudonimizar (reversível, com uma chave guardada à parte) ainda é **dado pessoal** sob a LGPD. Só a **anonimização irreversível** tira o dado do escopo da lei, e cuidado com a **reidentificação** por cruzamento de bases (*k-anonimato*).

Anonimizando o cadastro de clientes

ANTES — CADASTRO (DADO PESSOAL)

nome	CPF	CEP	idade	gasto 12m
João da Silva	123.456.789-00	95080-200	34	R\$ 1.240
Maria Souza	987.654.321-00	90210-150	61	R\$ 890



DEPOIS — BASE ANONIMIZADA PARA ANÁLISE

nome supressão	cliente_id hash do CPF	região generalização	faixa generalização	gasto 12m mantido
— removido	c4a7f1e9	95080-***	30–39	R\$ 1.240
— removido	9b2e80a3	90210-***	60–69	R\$ 890

O **gasto** continua disponível para o modelo de demanda — o que sai é só o que **aponta para a pessoa**.

Transformações de dados

01

Simbólico → numérico

Conversão de valores categóricos para números

02

Numérico → simbólico

Discretização de valores contínuos em categorias


03

Normalização

Ajuste de valores numéricos a propriedades comuns

Conversão de valores ordinais

Muitos algoritmos (Redes Neurais, SVMs...) só trabalham com variáveis numéricas. Para **ordinais**, a ordem deve ser preservada, estratégia comum: associar inteiros crescentes.



A estratégia pode inserir **distorções relativas**, as diferenças entre símbolos são subjetivas.

Conversão de nominais: one-hot

Codificação **1-de-k** : um atributo binário para cada valor nominal.

- Mantém quaisquer dois vetores equidistantes
- Atributos binários descorrelacionados e assimétricos

cor	am	verm	verde	azul
amarelo	1	0	0	0
vermelho	0	1	0	0
verde	0	0	1	0
azul	0	0	0	1

LEMBRE-SE

Toda transformação altera a informação que temos sobre o dado: assim como achatar uma imagem em um vetor perde a relação espacial, codificar categorias muda distâncias e correlações. Transforme de forma consciente.

Texto vira vetor: Bag-of-Words

O mesmo princípio do one-hot para **texto**: cada documento vira um vetor que **conta quantas vezes** cada palavra do vocabulário aparece. A **ordem** das palavras é descartada, daí o nome "saco de palavras".

3 AVALIAÇÕES DE PRODUTOS

D1 *"faca corta bem"*

D2 *"panela boa, panela barata"*

D3 *"faca boa, panela boa"*

VOCABULÁRIO

faca

corta

bem

panela

boa

barata

doc	faca	corta	bem	panela	boa	barata
D1	1	1	1	0	0	0
D2	0	0	0	2	1	1
D3	1	0	0	1	2	0

panela aparece 2× em D2 → conta a **frequência**, não só a presença (one-hot seria 0/1).

panela aparece 2x em D2 → conta a **frequência**, não só a presença (one-hot seria 0/1).

Atributos nominais com muitos valores

O PROBLEMA

Atributo = **país** : 193 membros da ONU exigiriam 192 atributos extras.

Dados muito esparsos → **maldição da dimensionalidade**.

SOLUÇÕES COM CONHECIMENTO DE DOMÍNIO


- Agrupar em menos valores (ex.: 7 continentes)
- Descrever com pseudo-atributos: PIB, população, IDH, temperatura média...

Não há abordagem sempre melhor, no free lunch!


Discretização: três estratégias

Transformar valores contínuos em intervalos (o atributo vira categórico ordinal).


Larguras iguais



Frequências iguais



k-means (não-superv.)



Normalização: re-escalar e padronizar

Re-escalar

Muda a unidade de medida. Uso comum: levar ao intervalo $[0, 1]$ ou $[-1, +1]$.

$$x' = (x - \text{mín}) / (\text{máx} - \text{mín})$$

Padronizar (z-score)

Subtrai a média (μ) e divide pelo desvio (σ) $\rightarrow$ distribuição normal padrão.

$$z = (x - \mu) / \sigma$$



POR QUE IMPORTA

Em **idade** $\times$ **salário**, as diferenças de salário são muito maiores e funcionam como "peso" em cálculos de distância (ex.: Euclidiana).

Se isso não é desejável, **padronize**.

z-score: como a distribuição muda

Padronizar **reposiciona e re-escala** os dados, sem deformar o **formato** da distribuição.



Idade	z	Salário	z
22	-1,44	R\$ 2.100	-1,15
35	-0,59	R\$ 4.500	-0,73
58	+0,92	R\$ 12.000	+0,58
64	+1,31	R\$ 18.000	+1,64

centro → 0

escala → σ=1

forma preservada

Anos e milhares de reais passam a viver na **mesma escala** — agora comparáveis em distância.

Feature engineering

Criar **novos atributos** a partir dos existentes, com conhecimento de domínio, muitas vezes o que mais melhora um modelo.

data 2024-06-15

→ dia da semana, fim de semana?

peso & altura

→ $IMC = \text{peso} / \text{altura}^2$

transações

→ gasto médio mensal

texto livre

→ número de palavras, sentimento

POR QUE IMPORTA

Boas features deixam o padrão **explícito** para o algoritmo.

Costuma render mais que trocar de modelo, mas exige entender o domínio.

Redução de dimensionalidade

Muitos atributos trazem ruído, custo computacional e *overfitting*, a **maldição da dimensionalidade**. A ideia é manter o sinal com menos variáveis.

Seleção de atributos

Escolhe um subconjunto dos atributos **originais** (mantém a interpretabilidade).

- **Filtro**: correlação, variância, qui-quadrado
- **Wrapper** : busca guiada pelo desempenho do modelo
- **Embedded** : regularização Lasso, importância em árvores

Extração de atributos

Cria **novos** atributos combinando os originais (mais compacto).

- **PCA** : componentes de máxima variância (linear)
- **t-SNE / UMAP**: visualização não-linear
- **Autoencoders** : compressão aprendida por redes

GANHOS

Menos **ruído** e custo


Menos **overfitting**

Permite **visualizar** 2D / 3D

Exemplo: PCA em altura × peso

Dois atributos muito correlacionados carregam quase a **mesma informação**. O PCA gira os eixos para um só.

A nuvem alongada e o novo eixo PC1



2
atributos



1
componente

altura e peso viram um único índice de "porte".

VARIÂNCIA RETIDA

 **95%**


PC1 sozinho guarda 95% da informação, descartamos a 2ª dimensão quase sem perda.

Amostragem e Geração de Dados

Por que e como amostrar, o desafio do desbalanceamento, e a geração de dados sintéticos.

05

Por que amostrar? População × amostra



POR QUE NÃO USAR TUDO?

- Processar a base inteira pode ser **caro ou inviável**
- Viabiliza **exploração** e prototipação rápidas
- Permite separar **treino** e **teste**

A amostra só vale se for **representativa**, viés aqui contamina todo o resto.

Técnicas de amostragem

Selecionar um subconjunto **representativo**, para reduzir custo, viabilizar exploração e separar treino / teste.

A

Aleatória simples

Toda instância tem a mesma chance de ser sorteada.

B

Estratificada

Mantém as proporções de cada grupo / classe na amostra.

ATENÇÃO


Amostra **com reposição** permite repetir instâncias; **sem reposição** , cada uma aparece no máximo uma vez.

Exemplo: aleatória × estratificada

Base de clientes: **90% permanecem** · **10% cancelam (churn)**. Queremos uma amostra que represente os dois grupos.

Aleatória simples


sorteio cego, a classe rara pode sumir



0 de 20 são churn → modelo não aprende a classe rara.

Estratificada

preserva a proporção 90 / 10




2 de 20 são churn → mesma proporção da população real.

O problema do desbalanceamento de classes

Fraude, doenças raras, churn: a classe de interesse é a **minoria**. O modelo tende a ignorá-la, e ainda parecer bom.

Undersampling


Reduz a classe **majoritária** até equilibrar.



Simples, mas **descarta dados** potencialmente úteis.

Oversampling

Aumenta a classe **minoritária** até equilibrar.



Duplicar arrisca *overfitting*, **SMOTE** gera pontos novos.

CUIDADO

Reamostre **apenas o treino**. O teste deve refletir a proporção **real**.

E não confie só na acurácia, use precisão, recall e F1.

SMOTE: oversampling da classe minoritária

Synthetic Minority Over-sampling Technique, o tratamento clássico para **classes desbalanceadas**.

COMO FUNCIONA

- 1** Para cada instância da classe minoritária, encontre seus **k vizinhos mais próximos**.
- 2** Sorteie um vizinho e crie um **ponto sintético no segmento** entre os dois.
- 3** Repita até a classe atingir o **balanceamento** desejado.

$$x_{\text{novo}} = x_i + \lambda \cdot (x_{\text{vizinho}} - x_i), \lambda \in [0, 1]$$


SMOTE × duplicar

Oversampling simples **repete** instâncias → favorece *overfitting*.
SMOTE gera **pontos novos**, ampliando a fronteira da classe.

Exemplo: SMOTE no espaço de atributos

Detecção de fraude: **990 normais** contra **10 fraudes**. SMOTE preenche a região da classe rara com pontos sintéticos.

Interpolando entre vizinhos



• majoritária • minoritária real • sintética (SMOTE)

ANTES → DEPOIS

10 fraudes → **~990** balanceado



POR QUE NÃO DUPLICAR

Cópias idênticas empilham pontos no mesmo lugar. SMOTE **cria pontos novos no meio** , ensinando a fronteira real da classe.

Geração de dados sintéticos

Dados **gerados artificialmente** que imitam as propriedades estatísticas dos dados reais.

POR QUE GERAR

- Dados reais **escassos** ou caros de rotular
- **Privacidade**: substituir dados sensíveis
- **Balancear** classes raras
- **Simular** cenários e casos extremos

COMO GERAR

- Amostrar de uma **distribuição** ajustada
- **SMOTE** e oversampling (tabulares)
- Modelos generativos, **GANs**, **VAEs**, **difusão**
- **Simulação** baseada em regras / física

CUIDADOS


Dado sintético pode **propagar vieses** do original e não representa o que não estava lá.

Sempre **validar a fidelidade** antes de usar.

Exemplo: prontuários sem expor pacientes

Um hospital não pode compartilhar dados reais. Um gerador aprende a **distribuição** e cria pacientes fictícios com as mesmas estatísticas.

Distribuição de idade, real × sintética



■ Dados reais --- Dados sintéticos

As curvas quase coincidem → o sintético **preserva o padrão** sem copiar registros.

ESTATÍSTICA PRESERVADA

Idade média	Desvio
42 → 42	11 → 12

PRIVACIDADE GARANTIDA

Nenhuma linha sintética corresponde a um paciente real, pode ser compartilhada para pesquisa.

Para dados textuais, temos uma alternativa a mais

O SMOTE interpola números; um **LLM** escreve registros plausíveis a partir de uma instrução em linguagem natural, útil sobretudo para **texto** e **casos raros**.

VOCÊ DESCREVE, ELE PREENCHE

"Gere **50** reclamações de clientes sobre uma **panela antiaderente**, em PT-BR, com colunas: *texto*, *sentimento*, *motivo*. Inclua casos de **defeito raro**."

Saída direta como **CSV/JSON** : texto, conversas, rótulos e tabelas sob medida, em minutos.

QUANDO BRILHA

- Dados de **texto** e linguagem (NLP)
- **Aumentar** casos raros e bordas
- **Prototipar** sem dados sensíveis
- Variar **tom**, **idioma** e **formato**

ARMADILHAS


- **Alucina** : valores que parecem certos e não são
- **Achata a diversidade**: repete o provável
- Pode **vazar** dados de treino do modelo
- Não representa o que o negócio **de fato viu**

Few-Shot: Podemos fornecer alguns exemplos para o modelo no seu prompt e orientá-lo a gerar dados seguindo o exemplo.

Mãos à obra no Orange Data Mining

Sem escrever uma linha de código: montamos um fluxo visual de widgets para explorar e preparar os dados de hoje.

O FLUXO QUE VAMOS CONSTRUIR



O que praticamos: colocar em prática a estatística descritiva, a exploração e o pré-processamento que vimos hoje.

Créditos e Referências

CRÉDITOS

Slides adaptados dos originais gentilmente cedidos pelos Profs. Rodrigo Coelho Barros, André Carvalho, Eduardo Hruschka e Ricardo Campello (ICMC-USP), e Pang-Ning Tan (MSU).

REFERÊNCIAS

Tan, P. N.; Steinbach, M.; Kumar, V. *Introduction to Data Mining*. Addison-Wesley, 2005.

Faceli et al. *Inteligência Artificial: Uma Abordagem de Aprendizado de Máquina*. LTC, 2011.